

# Decaf PA 1-B 说明

## 任务描述

在 PA1-A 中，我们借助 LEX 和 YACC 完成了 Decaf 的词法、语法分析。在这一部分，我们的任务与 PA1-A 相同，但不再使用 YACC，而是手工实现自顶向下的语法分析，并支持一定程度的错误恢复。

PA1-B 实验的重点是训练自顶向下语法分析/翻译的算法实现。对于词法分析程序，同学们直接利用 PA1-A 的实验结果即可。实验框架默认不包含 `Lexer.java` 文件，你只需要将 PA1-A 生成的 `Lexer.java` 文件复制过来即可。

对于语法分析程序，我们提供了 `Parser.java` 文件作为自顶向下语法分析的模板，其中有部分算法要求大家手工编码实现。而 `Parser` 类所依赖的 `Table` 类，由我们提供的 `pg.jar` 工具自动生成。`ant` 会自动调用该工具生成 `Table` 类，你需要通过修改 `Parser.spec` 文件来得到支持新语法特性的 `Table`。

本 README 文件只讲述与 PA1-A 有差异的部分，其他信息可参考 PA1-A 的 README 文件。

实验截止时间以网络学堂为准。请按照《Decaf 实验总述》的说明打包和提交。

## 本阶段涉及的工具和类的说明

实验框架与 PA1-A 基本相同，有差别的地方主要是以下几处：

(1) 在 PA1-A 中，我们手工编辑 `Lexer.l` 文件，再由 JFlex 自动生成 `Lexer.java`。本次实验框架不包含 `Lexer.l` 文件，你只需把 PA1-A 中自动生成的 `Lexer.java` 复制过来即可。

(2) 在 PA1-A 中，我们手工编辑 `Parser.y` 文件，再由 BYACC/J 自动生成 `Parser.java`。本次实验不提供 `Parser.y`，框架中提供了一份用于手工编码实现 LL(1) 分析的 `Parser.java` 模板，你需要基于该文件完成本次实验。

(3) 针对 LL(1) 分析所需的数据（包括 First 集合、Follow 集合和预测集合），本框架提供 `pg.jar` 工具，它根据 `Parser.spec` 文件所描述的文法，自动生成上述数据，并包装成 `Table` 类（位于 `Table.java` 文件）。因此，你只需要在 `Parser` 类中调用 `Table` 类中相对应函数，就可以访问到这些数据，从而实现 LL(1) 语法分析。请注意，我们已经在 `build.xml` 中定义好了调用 `pg.jar` 工具的逻辑，你只需修改 `Parser.spec`，然后用 `ant` 来构建，就能自动生成新的 `Table.java`。当你的 `Parser.spec` 描述有误时，`pg.jar` 工具会报错，请留意构建时工具输出的错误信息。

在 `TestCases` 目录下，是我们从最终测试集里面抽取出来的一部分测试用例，你需要保证你的输出和我们给出的标准输出是**完全一致**的。其中 `TestCases/S1+` 中的测例保证语法正确，`TestCases/S1-` 中的测例均有语法错误。

本阶段主要涉及的类和文件如下：

文件/类	含义	说明
BaseLexer	词法分析程序基础	根据 PA1-A 的实现进行修改
Lexer	词法分析器，主体是 yylex()	框架不提供，沿用 PA1-A 自动生成的程序
Parser.spec	LL(1)文法描述	该文件描述了增加新特性前 Decaf 语言的所有文法。你需要先阅读给出的 LL(1) 文法，然后增加新特性对应的 LL(1)文法
Table	语法分析所依赖的数据	由 pg.jar 工具根据文法描述 Parser.spec 自动生成，请勿修改
Parser	语法分析器	你需要基于该模板完成本次实验，请先阅读本类定义的所有成员变量和函数，然后实现其中的算法函数 parse
SemValue	文法符号的语义信息	可根据自己的需要进行适当的修改
tree/*	抽象语法树的各种结点	你要在此文件中定义实验新增特性的语法结点，但可以直接将阶段一（A）完成的结果复制过来（注意，是仅复制新增特性的语法结点，而非整个 Tree.java 文件）。
error/*	表示编译错误的类	不要修改
Driver	Decaf 编译器入口	调试时可以修改
Option	编译器选项	不要修改
Location	文法符号的位置	不要修改
utils/*	辅助的工具类	可以增加，但不要修改原来的部分
build.xml	Ant Build File	不要修改

修改好代码后，运行 ant，会在 result 目录下产生 decaf.jar 文件，启动命令行输入 java -jar decaf.jar 就可以启动编译器。不写任何参数的会输出 Usage。

测试和提交方法请参照《Decaf 实验总述》。

## 实验内容与提示

由于本次实验内容较多，且具有一定难度。建议分以下三个步骤来完成本次实验。

### 步骤一：阅读 LL(1)分析算法的实现

在 Lecture04 中，我们介绍了递归下降的 LL(1)分析方法，并给出了一系列非终结符对应的分析函数。例如为了分析文法

$$\langle \text{function} \rangle \rightarrow \text{FUNC ID ( } \langle \text{parameter\_list} \rangle \text{ ) } \langle \text{statement} \rangle$$

我们定义分析函数 ParseFunction:

```
void ParseFunction() {
    MatchToken(FUNC);
    MatchToken(ID);
    MatchToken(LPAREN);
    ParseParameterList();
    MatchToken(RPAREN);
    ParseStatement();
}
```

从 ParseFunction 的实现可以总结出：为了完成对非终结符 $\langle \text{function} \rangle$ 的分析，只需依次对 $\langle \text{function} \rangle$ 产生式右部的各符号进行分析。

- 遇到终结符（如 FUNC）时，调用 MatchToken 函数来匹配；
- 遇到非终结符（如 $\langle \text{parameter\_list} \rangle$ ）时，递归调用它对应的分析函数（如 ParseParameterList）进行分析。

此外，为了将分析出的非终结符 $\langle \text{function} \rangle$ 所对应的分析结果（这里考虑其 AST 结点的值）记录下来，我们可以像 PA1-A 实验那样，用一个 SemValue 类的对象记录每个语法符号对应的结果，然后根据这些结果完成某个用户定义的语义动作。据此，上述分析函数修改为：

```
SemValue ParseFunction() {
    SemValue[] params = new SemValue[6 + 1];
    params[1] = MatchToken(FUNC);
    params[2] = MatchToken(ID);
    params[3] = MatchToken(LPAREN);
    params[4] = ParseParameterList();
    params[5] = MatchToken(RPAREN);
    params[6] = ParseStatement();

    params[0] = new SemValue();
    // do user-defined actions
    return params[0];
}
```

这里，我们用长度比产生式右部符号数多 1 的 SemValue 数组，来缓存对产生式右部各符号进行分析得到的结果（params[1]到 params[6]）。然后，我们执行用户定义的语义动作，即用户访问并修改 params 数组中的数据。最终，返回 params[0]作为非终结符 $\langle \text{function} \rangle$ 的分析结果。

以上讨论了非终结符对应于单一产生式的情形。如果某个非终结符对应于多个产生式（即存在多种分析方法），那么我们需要先通过查看 lookahead 符号来决定使用哪一个产生式（哪一种分析方法），然后再利用上述方法分析该产生式右部的符号。在 Java 语言中，我们用一个 switch-case 语句即可实现根据 lookahead 符号选择相应产生式的逻辑。具体例子请见 Lecture04，这里不再赘述。

形如 ParseFunction 的分析函数是**类似**的，为了避免重复，我们在 Parser 类中把它们统一为**通用**的 parse 函数，**并把非终结符（如<function>）作为第一个参数传入**：

```
SemValue parse(int symbol, Set<Integer> follow)
```

其中 symbol 为待分析的非终结符。若分析成功，则返回值存储了 symbol 所对应 AST 结点的值；若分析失败，则返回 null。我们提供的代码框架中实现了不带错误恢复功能的 LL(1) 分析算法，实现思路与

```
SemValue ParseFunction()
```

类似。请注意，框架中给出的实现仅在输入程序语法正确的情况下有效；针对语法错误的程序输入，抛异常是正常现象。在完成步骤二后，你的程序对于即使语法错误的输入也不应该抛异常。请仔细阅读这部分的代码，有必要时插入一些打印语句输出调试信息，以便理解该算法的思路。这一阶段，你无需关心第二个参数 follow。

## 步骤二：增加错误恢复功能

接下来，你需要**修改** parse 函数，使其**具备错误恢复**的功能。即当输入的 Decaf 程序出现语法错误时，它还能对后续的程序**继续**分析，直至读到文件尾。在 Lecture04 中，我们介绍了应急恢复和短语层恢复的方法。这里，我们提出一种**介于二者之间**的错误恢复方法：

与应急恢复的方法类似，当分析非终结符  $A$  时，若当前输入符号  $a \notin \text{Begin}(A)$ ，则先报错，然后跳过输入字符串中的一些符号，直至遇到  $\text{Begin}(A) \cup \text{End}(A)$  中的符号：

- 若遇到的是  $\text{Begin}(A)$  中的符号，可恢复分析  $A$ ；
- 若遇到的是  $\text{End}(A)$  中的符号，则  $A$  分析失败，返回 null，继续分析  $A$  后面的符号。

这个处理方法与应急恢复方法的不同之处在于：

- 我们用集合  $\text{Begin}(A) = \{s \mid M[A, s] \text{非空}\}$ （其中， $M$  为预测分析表）来代替  $\text{First}(A)$ 。由于  $\text{First}(A) \subseteq \text{Begin}(A)$ ，我们能少跳过一些符号。
- 我们用集合  $\text{End}(A) = \text{Follow}(A) \cup F$ （其中， $F$  为 parse 函数传入的第二个参数）来代替  $\text{Follow}(A)$ 。由于  $F$  集合包含了  $A$  各父节点的 Follow 集合，我们既能少跳过一些符号，同时由于结束符必然属于文法开始符号的 Follow 集合，本算法无需额外考虑因读到文件尾而陷入死循环的问题。这个处理方法借鉴了短语层恢复中 EndSym 的设计。

另外，当匹配终结符失败时，只报错，但不消耗此匹配失败的终结符，而是将它保留在剩余输入串中。这部分的处理**已经在** matchToken 函数中**实现**。

错误恢复中的一个难题是，某一处的语法错误可能带来后续多处的误报。本实验，我们并不要求你的分析程序多么完美，能达到多低的误报率，而是希望能**避免某些典型情形**下的误报。只要你的程序针对 TestCases/S1-给出的所有测例，既不漏报错，也不多报错，就视为满足实验要求。为了达到这一目标，你既可以按照上文提出的策略来实现错误恢复，也

可以自己提出一个策略来实现错误恢复。如果是后者，我们允许你根据实际编码的需求**任意修改** Parser 类，请务必在**实验报告**中清晰地描述出你的策略以及对 Parser 所作的修改。

### 步骤三：增加新特性对应的 LL(1) 文法

在正确实现 LL(1) 分析算法之后，我们就能通过在 Parser.spec 中添加新的文法，调用 pg.jar 工具自动完成 Table 类数据的更新，从而实现对新特性的语法分析支持。Parser.spec 文件的格式与 Parser.y 类似，Spec 文件的文法规范参见工具的 wiki (<https://github.com/paulzfm/LL1-Parser-Gen/wiki/1.-Specification-File>)。你需要做的修改主要分为两个部分：一是在 token 段**加上新增的终结符**；二是加上新特性对应的 **LL(1)文法和语义动作**。为了确保能正确生成 Table，请不要修改 Parser.spec 中已经给出的部分。

与 PA1-A 不同的是，Parser.spec 要求 LL(1)文法，除了 else 语句处的警告

```
Warning: conflict productions at line ***:
ElseClause -> ELSE Stmt
ElseClause -> <empty>
```

外，在新增文法后，工具不应该再报出任何其他的警告、甚至错误。

为方便，以下重新列出新增加的语言特性。

#### 1. 整复数类型的支持：

- 1) 新增关键字 **complex**，用于声明复数类型的变量。即，将下列语法规则

```
Type ::= int | bool | string | ...
```

修改为

```
Type ::= int | bool | string | complex | ...
```

- 2) 同时，应在词法分析中增加识别复数常量虚部的功能。表示形式为  $a+bj$ ，其中  $a$  为实部， $bj$  为虚部。

新增终结符 `imgconst` 表示复数常量的虚部：

```
Constant ::= intconstant | boolconstant | imgconstant | ...
```

- 3) 新增表达式：`@e` 表示获取复数表达式  $e$  计算结果的实部（整数），`$e` 表示获取复数表达式  $e$  计算结果的虚部（整数），`#e` 表示将整数表达式  $e$  的计算结果强制转换为复数。（注：本学期，限定复数表达式仅包含加法（+）和乘法（\*）运算。）

参考语法：

```
Expr ::= @Expr | $Expr | #Expr | ...
```

- 4) 新增语句复数打印语句（关键字 **PrintComp** 开头）表示复数的显示，其参数要求具有复数类型。

参考语法：

```
Stmt ::= PrintCompStmt ; | ...
PrintCompStmt ::= PrintComp ( Expr+, )
```

#### 2. Case 表达式的支持。

新增 case 表达式（新增关键字 **case** 和 **default**），形如

```
case (表达式) {
    常量1: 表达式1;
```

```

        常量2: 表达式2;
        ...
        常量n: 表达式n;
        default: 表达式n+1;
    }

```

其语义解释与 C 语言的 switch-case 控制结构相类似，不同之处只是表达式计算，而非执行语句。

注：本学期的 case pattern（即上面的常量 1、常量 2、……、常量 n）仅限于整数类的常量运算数。

参考语法：

```

Expr ::= case (Expr) { ACaseExpr* DefaultExpr } | ...
ACaseExpr ::= Constant:Expr ;
DefaultExpr ::= default:Expr ;

```

### 3. 支持 super 表达式。

类似于 this 表达式，但语义不同，详见后续阶段的说明。

参考语法：

```

Expr ::= super | ...

```

### 4. 支持对象复制。

新增表达式：深复制 **dcopy**(e) 和浅复制 **scopy**(e), **dcopy** 和 **scopy** 为新增关键字，语义说明参见后续阶段。

参考语法：

```

Expr ::= dcopy(Expr) | scopy(Expr) | ...

```

### 5. 支持串行循环卫士语句。

串行循环卫士语句的一般形式如

$$\mathbf{do} \ E_1 : S_1 \ || \ E_2 : S_2 \ || \ \dots \ || \ E_n : S_n \ \mathbf{od}$$

我们将其语义解释为：

- (1) 依次判断布尔表达式  $E_1$  ,  $E_2$  , ...,  $E_n$  的计算结果。
- (2) 若计算结果为 **true** 的第一个表达式为  $E_k$  ( $1 \leq k \leq n$ )，则执行语句  $S_k$ ；转 (1)。
- (3) 若  $E_1$  ,  $E_2$  , ...,  $E_n$  的计算结果均为 **false**，则跳出循环。

本学期实验拟新增串行循环卫士语句（新增关键字 **do** 和 **od**）。

参考语法：

```

Stmt ::= DoStmt ; | ...
DoStmt ::= do DoBranch* DoSubStmt od
DoBranch ::= DoSubStmt |||
DoSubStmt ::= Expr : Stmt

```

此外，针对原 Decaf 语言的文法

$$\text{SimpleStmt} ::= \text{LValue} = \text{Expr} \mid \text{Call} \mid \varepsilon$$

由于将其改写为等价的 LL(1)文法十分复杂，为了简化，本阶段我们将上述文法扩展为

$$\text{LValue} ::= \text{Expr}$$
$$\text{SimpleStmt} ::= \text{LValue} = \text{Expr} \mid \text{Expr} \mid \varepsilon$$

你在进行实验时无需修正此文法。但是之后阶段的作业，请大家以原 Decaf 语言的 LValue 文法为准。AST 打印规范同 PA1-A，请参见：

<https://github.com/paulzfm/decaf-PA-1-AST/blob/master/ASTPrintFormat.md>

错误输出格式也同 PA1-A。

## 关于 pg.jar 工具

本实验所用的工具基于原 LL1-Parser-Gen (<https://github.com/paulzfm/LL1-Parser-Gen>)，但是作了修改（见 course 分支：<https://github.com/paulzfm/LL1-Parser-Gen/tree/course>）。原来的工具可以生成完整的 Parser，但是不具备错误恢复的功能，且在生成的代码基础上添加错误恢复的功能十分困难。因此，我们对此工具作了修改，使其能生成 Table 类，用户基于生成的 Table 类，可以更加自由地实现自己的 Parse 函数，并实现错误恢复的功能。感兴趣的同学可以用原工具生成 Decaf 语言的 Parser 代码，并阅读代码，理解 LL(1)分析算法的过程和实现。

## 实验评分

1. 编码实现部分评分方式与 PA1-A 相同，看所提交程序的输出是否与标准输出**完全一致**，包括一部分**未公开**的测试样例。其中语法错误的测例与 TestCases/S1-十分类似，只要你不采用**作弊**的实现方法，如果你的程序能正确处理 TestCases/S1-中的测例，那么它也能正确处理隐藏测例。请注意，针对语法错误的测例，我们依然要求你的输出与标准输出完全一致。本部分占分 **80%**，其中语法正确部分的测例占分 **40%**，语法错误部分的测例占分 **40%**。

2. 实验报告除了需要说明**本阶段工作**外，还要着重阐述清楚以下**两个问题**：

(1) Decaf 语言由于允许 if 语句的 else 分支为空，因此不是严格的 LL(1)语言，但是我们的工具依然可以处理这种冲突。请根据工具所生成的预测分析表中 if 语句相关项的预测集合先做猜测，并对照工具 wiki (<https://github.com/paulzfm/LL1-Parser-Gen/wiki/2.-Strict-Mode>)，理解本工具的处理方法。请在实验报告中说明此方法的**原理**，并举一个你自己构造的例子加以说明。

(2) 无论何种错误处理方法，都无法完全避免误报的问题。请举出一个语法错误的 Decaf 程序**例子**，用你实现的 Parser 进行语法分析会带来误报。并说明**为什么**你用的错误处理方法无法避免这种误报。

另外，如果你采用了不同于步骤二中提出的错误处理方法，请务必在实验报告中清晰地描述出你的**策略**以及对 Parser 所作的**修改**。

本部分占分 **20%**。